M2: DATA QUALITY REPORT

Exploratory Data Analysis (KMTI21133) · Bobot 10% · Dikumpulkan pada pertemuan 5

Nama tim	Ajojing
Anggota dan peran	Shafhan Farizi (0110223019) - Koordinator dan penanggung jawab analisis Abdul Aziz Alfarizi (0110225057) - Penanggung jawab data dan provenance Ziqri Akbar Ashari (0110225120) - Penanggung jawab notebook dan data cleaning Muhammad Rijal Jiddan (0110221246) - Penanggung jawab analisis, visualisasi, laporan, dan privasi
Judul proyek	Analisis kualitas data transaksi Supermarket Sales
Pertanyaan payung	Bagaimana pola penjualan dan pendapatan kotor pada transaksi supermarket berdasarkan waktu, cabang, kategori produk, tipe pelanggan, dan metode pembayaran selama periode Januari–Maret 2019?
Dataset	Supermarket Analysis
Tautan repositori	https://github.com/shafhan-farizi/ajojing
Tanggal laporan	Senin, 19 Oktober 2026

1. Ringkasan

Dataset SuperMarket Analysis.csv berisi 1.000 transaksi dan 17 kolom. Pemeriksaan awal tidak menemukan nilai kosong, placeholder umum, spasi di tepi nilai teks, duplikat persis, maupun Invoice ID berulang. Pemeriksaan rentang pada tujuh kolom numerik dan pemeriksaan empat hubungan antarkolom tidak menunjukkan pelanggaran berdasarkan aturan yang digunakan. Perbaikan utama yang diterapkan adalah konversi Date dan Time dari teks menjadi tipe temporal, penambahan kolom year_month, serta pseudonimisasi Invoice ID sesuai kamus data sebelumnya. Karena tidak ada masalah nilai yang terdeteksi, nilai numerik dan kategori tidak diimputasi, dihapus, atau digabung. Data layak dilanjutkan ke analisis eksploratif dengan catatan bahwa pertanyaan payung proyek perlu diselaraskan dengan isi dataset dan metadata sumber tetap perlu diverifikasi.

2. Data dan cara memeriksanya

2.1 Asal data

Butir	Isi
Nama sumber	Kaggle
Tautan atau instansi	https://www.kaggle.com/datasets/faresashraf1001/supermarket-sales
Tanggal pengambilan	Kamis, 01 Oktober 2026
Lisensi atau nomor izin	Apache 2.0
Kalimat sitasi	Data sekunder mengenai transaksi penjualan ritel yang dianalisis dalam laporan ini bersumber dari dataset publik 'Supermarket Sales' yang diunggah oleh kontributor Fares Ashraf di platform Kaggle dan didistribusikan di bawah lisensi Apache 2.0.

2.2 Ukuran dan cakupan

Dataset memiliki 1.000 baris dan 17 kolom. Satu baris merepresentasikan satu transaksi/faktur pada dataset penjualan supermarket. Nilai Date mencakup 1 Januari sampai 9 Maret 2019 setelah ditafsirkan dengan format bulan/hari/tahun. Format tanggal tersebut diasumsikan dari representasi nilai pada sumber dan harus dikonfirmasi bila dokumentasi berbeda.

2.3 Cara pemeriksaan

Pemeriksaan dilakukan menggunakan Python dan pandas: dimensi serta tipe data, statistik deskriptif, missing value sejati, placeholder umum, spasi awal/akhir pada teks, kategori unik, duplikat persis, duplikat berdasarkan Invoice ID, aturan rentang untuk tujuh kolom numerik, dan konsistensi hubungan antarkolom. Setelah pipeline dijalankan, tipe tanggal/waktu, jumlah baris, kolom, missing value, duplikat, kategori, serta statistik Rating diverifikasi ulang. Tidak dilakukan verifikasi dengan pemilik data karena dataset merupakan data sekunder publik.

3. Temuan kualitas data

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Validitas	Date, Time	Tipe data awal object, perlu tipe temporal	2	Sedang	Konversi ke datetime; cek hasil konversi
Keunikan	Seluruh baris	Duplikat persis tidak ditemukan	0	Rendah	Tidak menghapus baris
Keunikan	Invoice ID	ID transaksi berulang tidak ditemukan	0	Rendah	Pseudonimisasi ID; pertahankan seluruh transaksi
Kelengkapan	Semua kolom	Missing value sejati tidak ditemukan	0	Rendah	Tidak melakukan imputasi
Konsistensi	Kolom teks	Tidak ada spasi tepi atau placeholder dari daftar pemeriksaan	0	Rendah	Tidak ada normalisasi kategori substantif
Validitas	7 kolom numerik	Tidak ada pelanggaran aturan rentang yang diuji	0	Rendah	Nilai dipertahankan
Konsistensi	4 hubungan antarkolom	Seluruh relasi yang diuji konsisten	0	Rendah	Nilai dipertahankan

Keparahan ditentukan berdasarkan dampak potensial pada analisis. Temuan tipe data tanggal/waktu dipandang sedang karena dapat menghambat analisis tren jika tetap diperlakukan sebagai teks; temuan lain berkeparahan rendah karena pemeriksaan tidak menunjukkan masalah yang mengubah nilai atau jumlah transaksi.

3.1 Pola nilai kosong

Tidak ada kolom dengan persentase missing value di atas 5%; bahkan jumlah missing value teramati adalah nol untuk seluruh kolom. Karena tidak ada kekosongan yang dapat dianalisis, klasifikasi MCAR/MAR/MNAR tidak diterapkan. Hasil ini tidak membuktikan bahwa proses pengumpulan data bebas dari bias atau bahwa tidak ada nilai yang hilang sebelum dataset dipublikasikan.

4. Keputusan pembersihan dan alasannya

1. Konversi Date dan Time

Masalah	Date dan Time bertipe object meskipun merepresentasikan waktu.
Dugaan pola	Data Date dan Time diduga memiliki masalah representasi tipe data (data type), bukan masalah nilai yang hilang. Kedua kolom masih terbaca sebagai teks (object), padahal merepresentasikan tanggal dan waktu transaksi. Belum ada indikasi bahwa nilai tanggal atau waktu tidak valid berdasarkan pemeriksaan konversi.
Keputusan	Ubah Date memakai format %m/%d/%Y dan Time memakai format %I:%M:%S %p ke datetime; tidak ada nilai gagal konversi pada pemeriksaan.
Alasan	Tipe temporal diperlukan agar pengurutan dan agregasi waktu berjalan benar. Mengabaikan tipe data berisiko menghasilkan pengurutan teks, bukan kronologis.
Alternatif ditolak	Menghapus kedua kolom ditolak karena tanggal dan waktu penting untuk pertanyaan tren.
Dampak	Tidak ada baris dibuang; analisis temporal dapat dilakukan.

2. Penanganan missing value

Masalah	Tidak ditemukan nilai kosong pada seluruh 1.000 baris dataset berdasarkan pemeriksaan awal.
Dugaan pola	Tidak terdapat nilai kosong yang terdeteksi, sehingga mekanisme MCAR, MAR, atau MNAR tidak dapat ditentukan berdasarkan pemeriksaan ini. Kondisi tersebut tidak membuktikan bahwa proses pengumpulan data bebas dari kehilangan informasi.
Keputusan	Tidak melakukan imputasi maupun penghapusan baris berdasarkan nilai kosong.
Alasan	Seluruh kolom tidak menunjukkan nilai kosong berdasarkan pemeriksaan awal. Oleh karena itu, imputasi menggunakan mean, median, atau modus tidak diperlukan. Mengisi nilai yang sebenarnya sudah tersedia justru berisiko mengubah data tanpa dasar.
Alternatif ditolak	Imputasi nilai kosong ditolak karena tidak ada nilai kosong yang perlu diisi. Penghapusan baris juga ditolak karena tidak terdapat baris yang perlu dihapus berdasarkan kriteria tersebut.
Dampak	Jumlah baris tetap 1.000 dan tidak ada nilai baru yang dibuat melalui imputasi. Pemeriksaan lanjutan tetap diperlukan untuk memastikan tidak ada placeholder yang menyamar sebagai nilai, misalnya -999 atau teks "unknown". Salin seluruh isian

3. **Penanganan duplikat**

Masalah	Duplikat persis = 0 dan Invoice ID duplikat = 0.
Dugaan pola	Pemeriksaan awal tidak menemukan baris duplikat persis maupun Invoice ID yang berulang. Dengan demikian, belum terdapat indikasi masalah keunikan pada baris transaksi atau pengenal transaksi dalam dataset yang diperiksa.
Keputusan	Tidak menghapus transaksi.
Alasan	Tidak ada bukti bahwa baris merupakan transaksi ganda; menghapus baris tanpa bukti berisiko kehilangan transaksi sah.
Alternatif ditolak	Menghapus baris berdasarkan kemiripan beberapa kolom ditolak karena transaksi berbeda bisa memiliki nilai transaksi serupa.
Dampak	Seluruh 1.000 baris dipertahankan.

4. V**aliditas numerik**

Masalah	Tujuh aturan rentang diuji pada harga, kuantitas, rating, pajak, sales, cogs, dan gross income; pelanggaran = 0.
Dugaan pola	Pemeriksaan terhadap aturan rentang pada kolom Unit price, Quantity, Rating, Tax 5%, Sales, cogs, dan gross income tidak menemukan pelanggaran. Oleh karena itu, belum terdapat indikasi nilai numerik yang melanggar aturan validitas yang digunakan dalam pemeriksaan.
Keputusan	Nilai numerik dipertahankan.
Alasan	Seluruh nilai lolos aturan yang ditentukan sehingga tidak ada dasar untuk mengubah atau mengosongkan nilai.
Alternatif ditolak	Mengubah nilai ekstrem hanya karena terlihat tinggi/rendah ditolak karena bukan bukti kesalahan.
Dampak	Distribusi numerik tidak bergeser akibat cleaning.

5. Konsistensi hubungan transaksi

Masalah	Tidak ada pelanggaran pada cogs = Unit price × Quantity, Tax 5% = 5% × cogs, Sales = cogs + Tax 5%, dan gross income = Tax 5%.
Dugaan pola	Pemeriksaan hubungan antara cogs, Unit price, Quantity, Tax 5%, Sales, dan gross income tidak menemukan ketidaksesuaian berdasarkan rumus yang diuji. Dengan demikian, belum terdapat indikasi inkonsistensi perhitungan antarkolom pada dataset yang diperiksa.
Keputusan	Tidak menimpa nilai turunan.
Alasan	Hubungan antarkolom konsisten pada data; menimpa nilai yang sudah konsisten tidak memberi manfaat dan dapat memperkenalkan kesalahan.
Alternatif ditolak	Menghitung ulang dan menimpa seluruh nilai ditolak agar nilai sumber tetap terlacak.
Dampak	Tidak ada nilai penjualan atau pendapatan yang diubah.

6. Pseudonimisasi Invoice ID

Masalah	Invoice ID merupakan pengenal transaksi dan kamus data sebelumnya menetapkan tindakan hash.
Dugaan pola	Invoice ID merupakan pengenal unik untuk setiap transaksi. Meskipun pemeriksaan awal tidak menemukan ID yang berulang, kolom ini tetap diperlakukan sebagai pengenal yang perlu dilindungi dalam data olahan. Pseudonimisasi dilakukan sebagai langkah perlindungan terhadap pengenal transaksi, bukan karena ditemukan masalah duplikasi atau nilai yang tidak valid.
Keputusan	Gunakan hash SHA-256 terpotong 16 karakter pada data olahan.
Alasan	Mengurangi paparan pengenal mentah dalam berkas hasil olahan. Hash tetap pseudonimisasi dan tidak menjamin anonimitas mutlak.
Alternatif ditolak	Menghapus ID seluruhnya ditolak karena pengenal dapat berguna untuk pelacakan transaksi dan verifikasi keunikan.
Dampak	ID tetap unik; data mentah tidak diubah.

5. Dampak pembersihan terhadap data

5.1 Sebelum dan sesudah

Ukuran	Sebelum	Sesudah	Catatan
Jumlah baris	1000	1000	Tidak ada baris dibuang.
Jumlah kolom	17	18	Bertambah satu kolom turunan year_month.
Total sel kosong	0	0	Tidak ada missing value atau kegagalan konversi.
Baris duplikat	0	0	Tidak ditemukan duplikat.
Jumlah kategori pada kolom kunci	6	6	Kategori dipertahankan.
Nilai unik pada kolom identitas	1000	1000	Tetap unik setelah pseudonimisasi.

5.2 Dampak terhadap sebaran

Kolom yang digunakan adalah Rating. Mean sebelum dan sesudah = 6.9727; median sebelum dan sesudah = 7.0000; simpangan baku sebelum dan sesudah = 1.7186. Pergeseran ketiga statistik adalah 0 karena nilai Rating tidak diubah. Ini merupakan hasil yang diharapkan karena tidak ditemukan pelanggaran rentang pada kolom tersebut; keputusan cleaning berfokus pada tipe tanggal/waktu dan pseudonimisasi ID.

6. Keterbatasan

- Data mentah tidak memuat missing value, tetapi hal ini tidak memungkinkan tim mengetahui apakah nilai tertentu telah hilang sebelum dataset dirilis.
- Tanggal diasumsikan memakai format bulan/hari/tahun. Jika dokumentasi sumber menetapkan format lain, rentang waktu dan analisis tren perlu diperiksa ulang.
- Aturan rentang rating 0–10 didasarkan pada nilai yang teramati; skala resmi perlu dicocokkan dengan dokumentasi sumber.
- Lisensi dan tanggal pengambilan yang dicatat di notebook sebelumnya belum diverifikasi secara independen pada halaman sumber.
- Pertanyaan payung proyek sebelumnya menyebut toko buah dan kolom Total, sedangkan dataset ini berisi transaksi supermarket dengan kolom Sales. Tim perlu menyelaraskan pertanyaan sebelum M3.
- Hash ID bersifat pseudonimisasi; data quasi-identifier seperti cabang, kota, tanggal, waktu, jenis pelanggan, dan gender tetap perlu dipertimbangkan sebelum repositori dipublikasikan.

7. Penanganan data pribadi

Butir	Keterangan
Kolom data pribadi pada data olahan	Invoice ID diperlakukan sebagai pengenal transaksi dan dipseudonimkan. Kolom Branch, City, Customer type, Gender, Date, dan Time diperlakukan sebagai quasi-identifier sesuai kamus data sebelumnya.
Tindakan penanganan yang diterapkan	Invoice ID di-hash pada data olahan; data mentah dipertahankan tanpa perubahan. Jangan menganggap hash sebagai anonimisasi mutlak.
Nilai k pada data yang diunggah	Notebook Pertemuan 3 mencatat k = 62 untuk kombinasi Branch, City, Customer type, dan Gender. Hitung ulang pada berkas final yang akan diunggah jika kolom/transformasi berubah.
Status repositori (publik atau privat)	Belum dapat diverifikasi dari berkas yang diunggah; isi publik/privat sesuai pengaturan repositori tim.
data/raw/ masuk .gitignore	Perlu dipastikan di repositori. Jangan mengunggah data mentah jika kebijakan tim/dosen meminta data mentah tetap lokal.

8. Langkah berikutnya

1. Selaraskan pertanyaan payung dan pertanyaan turunan dengan dataset supermarket serta nama kolom yang benar (`Sales`, bukan `Total`).
2. Verifikasi provenance, lisensi, dan tanggal pengambilan langsung dari halaman sumber dataset.
3. Jalankan notebook dari awal sampai akhir menggunakan Restart Kernel and Run All; periksa keluaran dan berkas data/processed.
4. Lakukan analisis univariat, outlier, dan visualisasi pada Pertemuan 6 tanpa menghapus nilai hanya karena ekstrem.
5. Pastikan data olahan, kamus data, cleaning log, dan pengaturan privasi repositori konsisten sebelum dikumpulkan.

Lampiran A — Cleaning log

https://github.com/shafhan-farizi/ajojing/blob/main/cleaning_log.md

Lampiran B — Peta keputusan manual

Tidak ada penggabungan kategori manual yang diterapkan karena pemeriksaan tidak menemukan sinonim atau salah ketik yang terbukti.